

옵션 A — 매니페스트 vocabulary EXTEND (확장)

REPLACE 가 아닌 EXTEND — 기존 어휘 유지 + MITRE TTP 추가 + semantic cluster normalize

pkgsentinel · 7팀 · 2026-05-28 · 매니페스트 표준 v2 제안

1. 문제 — Capability Ontology Mismatch

Task C 측정 결과 매니페스트 ON/OFF ablation 효과 = 3%p (예상보다 작음). 원인: 매니페스트 declared 어휘와 도구 detected 어휘 mismatch:

자체 매니페스트 어휘 (declared)	도구의 detected vocabulary
net.http, net.socket	network, llm-call, mcp-client
fs.read, fs.write	filesystem-read, filesystem-write
shell.exec, proc.spawn	shell, code-exec, dynamic-tool-load
env.read, secrets.read	env-secrets, credential-paths

→ vocabulary 차이로 모든 detected = undeclared. 단순 hardcoded mapping 정렬 (REPLACE) 은 측정 dataset 에 overfit — 사용자 우려대로 새 dataset 깨짐.

2. 해법 원리 — REPLACE 가 아닌 EXTEND


REPLACE vs EXTEND

접근	의미	위험
REPLACE (기각)	자체 어휘 → MITRE 로 교체	breaking change. 기존 자료 손해. overfit 위험
EXTEND (채택) ★	자체 어휘 *유지* + MITRE 어휘 *추가*	additive. 작성자 선택권 보장. overfit 0

EXTEND 원칙

- ★ 매니페스트 작성자가 자체 어휘 / MITRE / 우리 detected 어휘 *어느 것이든* 사용 가능
- 도구 내부에서 세 어휘를 같은 semantic cluster 로 normalize
- MITRE = 외부 anchor → 측정 dataset 무관하게 generalizable
- 표준 진화: 처음엔 자체 어휘로도 가능 → 점진적으로 MITRE 채택 유도
- 부수 효과: STIX 2.1 / SIEM 출력 자연 매핑, 학술 anchor 보강

원리 다이어그램



3. Semantic Cluster — 3 vocabulary 가 같은 의미로 EXTEND

같은 capability 의미를 자체/MITRE/detected 세 어휘로 표현 가능. 도구는 셋 모두 같은 cluster 로 normalize:

Cluster	자체 어휘 (사람 친화)	MITRE TTP (외부 표준)	우리 detected (legacy)
network	net.http, net.socket	T1071, T1071.001, T1090	network, llm-call, mcp-client
fs-read	fs.read	T1083	filesystem-read
fs-write	fs.write	T1565	filesystem-write
exec	shell.exec, proc.spawn, subprocess, dynamic_eval	T1059, T1106	shell, code-exec, dynamic-tool-load

secrets	env.read, secrets.read	T1552	env-secrets, credential-paths
data-collect	data.collect	T1119	memory-persistent, db-access
agent-comm	agent.communicate	T1090	agent-to-agent, mcp-server

→ 7개 핵심 cluster. 작성자가 어느 vocabulary 든 사용 가능 — 도구가 내부에서 cluster 단위로 비교. *세 어휘 모두 1급 시민*.

Cluster 추가는 자유 (생태계 확장)

위 7개는 핵심 baseline. 새 cluster (예: gpu, browser-control, blockchain) 추가는 표준 v2.x 확장으로. EXTEND 원칙은 새 cluster 에도 적용.

4. 매니페스트 표준 v2 — EXTEND 적용 example

Author A — 자체 어휘만 (사람 친화)

[tool.agentic]
version = "v2"
capabilities = ["net.http", "fs.read", "shell.exec"]
→ 도구가 normalize: {network, fs-read, exec}

Author B — MITRE 어휘만 (표준 anchor)

[tool.agentic]
version = "v2"
capabilities = ["T1071", "T1083", "T1059"]
→ 도구가 normalize: {network, fs-read, exec}

Author C — 혼합 (점진 채택)

[tool.agentic]
version = "v2"
capabilities = ["net.http", "T1083", "shell.exec"]
→ 도구가 normalize: {network, fs-read, exec} (셋 다 같은 결과)

★ 셋 다 동등하게 1급 시민. 도구가 cluster 기준 비교.

5. Overfit 회피 — EXTEND 가 어떻게 해결하나

접근	Overfit 위험	Generalization	이유
자체 vocabulary 만 (현 상태)	중	불확실	ontology mismatch — 작동 X
REPLACE — Hardcoded mapping	높음	새 dataset 깨짐	측정 dataset 보면서 정렬 → bias
EXTEND — 자체 + MITRE 둘 다 (★)	0 ★	Dataset 무관	외부 anchor (MITRE) + 호환성 유지

EXTEND 의 overfit 회피 메커니즘:

- MITRE 는 외부 사전 정의 표준 (NIST/CISA 권장) — 우리 측정 dataset 무관
- 자체 어휘 → MITRE mapping 은 *의미 기반* (cluster) 이지 *데이터 기반* 이 아님
- 새 cluster 추가 시도 같은 EXTEND 원칙 적용 — breaking change 없음
- 도구의 detected vocabulary 도 *추가* 라벨 (legacy + cluster 둘 다) — 호환

6. 구현 계획 — EXTEND 단계별

단계	작업 (EXTEND 원칙)	시간	산출
Phase 1	7개 cluster 정의 + 3-vocabulary 매핑 (이 문서)	1-2일	spec v2 + 예시
Phase 2	agentic/manifest.py — declared 어휘 normalize layer 추가 (자체 + MITRE + detected 모두 인식)	2일	normalize() 함수 + 단위 테스트
Phase 3	agentic/capability_detector.py — detected 가 cluster + legacy 둘 다 라벨	1-2일	backward compat + 새 cluster
Phase 4	Reference manifest 공개 — LangChain/MCP 등 (셋 다 vocabulary OK)	1주	GitHub 공개 + PR proposal

Phase 5	Task C 재측정 — cluster 기준 declared $\geq$ detected 비교	4-6h	진짜 매니페스트 효과 정량
---------	---	------	----------------

→ 총 약 2주. Phase 1 (이 문서) 가 회신 메일 immediate evidence. Phase 2-3 가 호환성 핵심.

7. 예상 효과 — counter-factual 기준

옵션 E counter-factual simulation (별첨 PDF) 결과 + 옵션 A 정렬 시 잠재 효과:

측정	Current	MITRE 정렬 후 (예상)	개선
정상 agentic 100 — FPR	28.0%	약 7-10%	-18%p ~ -21%p
악성 agentic 34 — Recall	20.6%	약 30-40%	+10%p ~ +20%p (declared diff)
agentic F1	약 0.30	약 0.50-0.55	+0.20 이상

★ 예상치는 옵션 E counter-factual (FPR -7%p) + declared diff 정밀화 추정. 실측은 Phase 5 에서.

8. 결론 — EXTEND 가 강화하는 contribution

원래 contribution (v1)

- Agentic capability 선언 표준 — declared $\leftrightarrow$ detected diff 검증

옵션 A — EXTEND 가 추가하는 contribution (v2)

- ★ Semantic cluster 7개 + 3 vocabulary 동시 지원 (자체 + MITRE + detected)
- MITRE ATT&CK 채택 — 외부 표준 anchor (NIST/CISA 권장)
- ★ EXTEND 원칙 — 작성자 선택권 보장 + 점진적 채택
- 측정 dataset 무관 — overfit 위험 0 (REPLACE 의 함정 회피)
- Backward compat — 기존 자체 어휘 매니페스트 그대로 작동
- Forward compat — 새 cluster 추가도 EXTEND 원칙
- 부수 효과: STIX/TAXII/SIEM 자연 매핑, 학술 anchor 견고

한 줄 요약

표준화 = REPLACE 가 아닌 EXTEND. 자체 + MITRE + detected 세 vocabulary 를 같은 cluster 로 normalize. 작성자 선택권 보장하며 overfit 회피 + 학술 anchor 강화. 매니페스트 표준 제안의 견고성과 채택성을 동시에 확보.

관련 자료: 2026-05-28-TaskC-agentic-FPR.pdf (현재 ablation 결과), results_option_e_simulation.json (counter-factual). MITRE ATT&CK: attack.mitre.org/techniques/enterprise/.